Estadística básica para entender datos

Media, mediana, varianza, desviación estándar, estandarización, normalización, suma acumulada y correlación

1. Para qué sirve la estadística

La estadística sirve para resumir, comparar e interpretar datos. Cuando tenemos muchos valores, mirarlos uno por uno no suele ser suficiente. Necesitamos herramientas que nos ayuden a responder preguntas como: cuál es el valor típico, si los datos son parecidos entre sí, si hay valores muy extremos o si dos variables parecen relacionarse.

En inteligencia artificial y ciencia de datos, estas ideas son especialmente importantes porque los modelos aprenden a partir de datos. Si no entendemos los datos, tampoco podremos interpretar correctamente lo que hace un modelo.

Un ejemplo sencillo

Imaginemos las notas de siete estudiantes:

```
notas = [4, 5, 6, 6, 7, 8, 10]
```

Con esta lista podemos preguntarnos varias cosas: qué nota representa mejor al grupo, si las notas están muy juntas o muy separadas, cuál es la nota central y si hay algún valor especialmente alto o bajo.

2. Datos, variables y valores

Un dato es una pieza concreta de información. Por ejemplo, 23 años, 7.5 puntos, 'Madrid' o True. Una variable es una característica que se puede observar en distintos casos: edad, nota, ciudad, altura, salario, número de ventas, etc.

Concepto	Significado	Ejemplo
Dato	Valor concreto que se observa.	Ana tiene 23 años.
Variable	Característica que puede tomar distintos valores.	Edad.
Conjunto de datos	Grupo de valores recogidos para estudiar algo.	[21, 23, 25, 30].
Observación	Cada caso o fila que estudiamos.	Un alumno, un cliente, una venta.

Tipos básicos de variables

Tipo	Qué representa	Ejemplos
Cuantitativa	Cantidad numérica con la que se pueden hacer operaciones.	Edad, nota, sueldo, precio.
Cualitativa	Categoría o etiqueta.	Color, ciudad, tipo de producto.
Discreta	Cantidad contable, normalmente sin decimales.	Número de hijos, pedidos, errores.
Continua	Cantidad que puede tomar valores intermedios.	Altura, peso, temperatura.

3. Medidas de tendencia central

Las medidas de tendencia central intentan responder a una pregunta sencilla: dónde está el centro de los datos. Las más importantes son la media, la mediana y la moda.

3.1. Media o promedio

La media es el promedio. Se calcula sumando todos los valores y dividiendo entre el número de datos.

```
media = suma de todos los valores / número de valores
```

Ejemplo con las notas [5, 10, 15]:

```
media = (5 + 10 + 15) / 3 = 30 / 3 = 10
```

La media resume el valor típico, pero tiene un problema importante: puede cambiar mucho si aparece un valor extremo.

Datos	Media	Interpretación
[5, 6, 7]	6	La media representa bastante bien al grupo.
[5, 6, 100]	37	La media queda arrastrada por el valor extremo 100.

3.2. Mediana

La mediana es el valor que queda justo en el centro cuando los datos están ordenados de menor a mayor. Es muy útil cuando hay valores extremos, porque no se deja arrastrar tanto como la media.

1. Ordenamos los datos de menor a mayor.
2. Si hay una cantidad impar de datos, la mediana es el valor central.
3. Si hay una cantidad par de datos, la mediana es el promedio de los dos valores centrales.

Ejemplo con cantidad impar de datos:

```
[4, 5, 6, 8, 10]  ->  mediana = 6
```

Ejemplo con cantidad par de datos:

```
[4, 5, 8, 10]  ->  mediana = (5 + 8) / 2 = 6.5
```

La mediana suele ser más representativa que la media cuando hay sueldos, precios de viviendas o cualquier dato donde pueda haber valores muy altos o muy bajos.

3.3. Moda

La moda es el valor que más se repite. Puede haber una moda, varias modas o ninguna moda clara si todos los valores aparecen el mismo número de veces.

```
[4, 5, 6, 6, 7, 8, 10]  ->  moda = 6
```

La moda es especialmente útil en datos categóricos. Por ejemplo, si preguntamos el color favorito de una clase, no tendría sentido calcular la media, pero sí podemos saber cuál es el color más repetido.

Media, mediana y moda comparadas

Medida	Pregunta que responde	Cuándo conviene usarla
Media	Cuál es el promedio.	Cuando los datos no tienen valores extremos importantes.
Mediana	Cuál es el valor central.	Cuando hay valores extremos o datos muy descompensados.
Moda	Cuál es el valor más frecuente.	Cuando queremos detectar el valor que más se repite.

4. Medidas de dispersión

Las medidas de dispersión indican si los datos están muy juntos o muy separados. Dos grupos pueden tener la misma media y, aun así, ser muy diferentes.

Observa estos dos grupos:

```
Grupo A = [6, 6, 6]  ->  media = 6

Grupo B = [3, 6, 9]  ->  media = 6
```

Los dos grupos tienen la misma media, pero no significan lo mismo. En el grupo A todos son iguales; en el grupo B los valores están más separados. Por eso necesitamos estudiar la dispersión.

4.1. Rango

El rango es la diferencia entre el valor máximo y el valor mínimo.

```
rango = valor máximo - valor mínimo
```

Ejemplo:

```
[4, 5, 6, 6, 7, 8, 10]  ->  rango = 10 - 4 = 6
```

El rango es fácil de calcular, pero depende solo de dos valores: el mayor y el menor. Si uno de ellos es extremo, el rango puede dar una imagen exagerada de la dispersión.

4.2. Desviación respecto a la media

Antes de entender la varianza, hay que entender la idea de desviación. Una desviación indica cuánto se aleja un valor de la media.

```
desviación = valor - media
```

Si la media es 7:

Valor	Cálculo	Desviación	Interpretación
4	4 - 7	-3	Está 3 puntos por debajo de la media.
7	7 - 7	0	Está exactamente en la media.
10	10 - 7	3	Está 3 puntos por encima de la media.

4.3. Varianza

La varianza mide el promedio de las diferencias al cuadrado respecto a la media. Dicho de forma sencilla: nos ayuda a saber si los datos están cerca o lejos de la media.

```
varianza = promedio de (valor - media)^2
```

Se elevan las diferencias al cuadrado por dos motivos: para que los valores negativos no se cancelen con los positivos y para dar más importancia a las diferencias grandes.

Ejemplo con las notas [4, 7, 10]:

4. Media: (4 + 7 + 10) / 3 = 7.
5. Diferencias respecto a la media: 4 - 7 = -3; 7 - 7 = 0; 10 - 7 = 3.
6. Diferencias al cuadrado: (-3)^2 = 9; 0^2 = 0; 3^2 = 9.
7. Promedio de esas diferencias: (9 + 0 + 9) / 3 = 6.

```
varianza = 6
```

Una varianza baja indica datos bastante parecidos entre sí. Una varianza alta indica datos más separados o irregulares.

4.4. Desviación estándar

La desviación estándar es la raíz cuadrada de la varianza. Se usa mucho porque vuelve a estar en las mismas unidades que los datos originales.

```
desviación estándar = raíz cuadrada de la varianza
```

En el ejemplo anterior:

```
desviación estándar = raíz cuadrada de 6 ≈ 2.45
```

Esto significa que, aproximadamente, las notas se alejan 2.45 puntos de la media. No debe interpretarse como una regla exacta para cada dato, sino como una medida general de separación.

Varianza y desviación estándar comparadas

Concepto	Qué mide	Ventaja	Dificultad
Varianza	Dispersión media al cuadrado.	Es útil para cálculos estadísticos.	Sus unidades quedan elevadas al cuadrado.
Desviación estándar	Dispersión en las unidades originales.	Es más fácil de interpretar.	Depende de haber calculado antes la varianza.

5. Valores extremos

Un valor extremo, también llamado outlier, es un dato muy alejado del resto. No siempre es un error: puede ser una observación real, pero conviene detectarlo porque puede cambiar mucho algunos cálculos.

Datos	Media	Mediana	Qué ocurre
[5, 6, 6, 7, 8]	6.4	6	Media y mediana son parecidas.
[5, 6, 6, 7, 100]	24.8	6	La media sube mucho por el 100; la mediana resiste mejor.

Por eso, antes de interpretar una media, conviene mirar si existen valores extremos. En muchos contextos la mediana puede explicar mejor el centro real de los datos.

6. Normalización y estandarización

En un conjunto de datos puede haber variables con escalas muy distintas. Por ejemplo, la edad puede moverse entre 0 y 100, mientras que el salario puede moverse entre 0 y 100000. Muchos algoritmos de machine learning funcionan mejor cuando las variables están en escalas comparables.

Al proceso de ajustar las escalas de las variables se le suele llamar escalado de características. Las dos técnicas más habituales son la normalización y la estandarización.

6.1. Normalización min-max

La normalización min-max transforma los datos para que queden dentro de un rango fijo, normalmente entre 0 y 1.

```
valor normalizado = (valor - mínimo) / (máximo - mínimo)
```

Ejemplo con [10, 20, 30]:

Valor	Cálculo	Resultado
10	(10 - 10) / (30 - 10)	0
20	(20 - 10) / (30 - 10)	0.5
30	(30 - 10) / (30 - 10)	1

La normalización es fácil de entender, pero es sensible a valores extremos. Si aparece un valor muy grande, puede comprimir demasiado el resto de datos.

6.2. Estandarización o z-score

La estandarización transforma cada valor según su distancia respecto a la media, medida en desviaciones estándar. Después de estandarizar, la variable queda centrada en 0 y con desviación estándar cercana a 1.

```
z = (valor - media) / desviación estándar
```

Un valor z se interpreta así: z = 0 significa que el dato está en la media; z positivo significa que está por encima; z negativo significa que está por debajo.

Valor z	Interpretación sencilla
0	El valor coincide con la media.
1	Está una desviación estándar por encima de la media.
-1	Está una desviación estándar por debajo de la media.
2	Está bastante por encima de la media.
-2	Está bastante por debajo de la media.

Ejemplo:

```
valor = 20, media = 10, desviación estándar = 5

z = (20 - 10) / 5 = 2
```

Interpretación: el valor 20 está 2 desviaciones estándar por encima de la media.

Normalización y estandarización comparadas

Técnica	Qué hace	Cuándo puede ser útil
Normalización	Coloca los datos en un rango fijo, por ejemplo de 0 a 1.	Cuando necesitamos valores dentro de un intervalo concreto.

Estandarización	Expresa cada dato según cuántas desviaciones estándar se aleja de la media.	Cuando queremos comparar variables con unidades distintas.

7. Suma acumulada

La suma acumulada consiste en ir sumando los valores paso a paso. Cada resultado contiene todo lo acumulado hasta ese momento.

```
datos = [2, 4, 6, 8]
```

Paso	Cálculo	Resultado acumulado
1	2	2
2	2 + 4	6
3	2 + 4 + 6	12
4	2 + 4 + 6 + 8	20

```
suma acumulada = [2, 6, 12, 20]
```

La suma acumulada es útil para estudiar ventas acumuladas, ahorro mensual, objetivos progresivos, ingresos totales o cualquier dato que se vaya sumando a lo largo del tiempo.

8. Correlación

La correlación mide si dos variables se mueven juntas de alguna manera. Por ejemplo, podemos estudiar si las horas de estudio se relacionan con la nota de un examen.

El coeficiente de correlación de Pearson suele representarse con la letra r y toma valores entre -1 y 1.

Valor de r	Interpretación
r cerca de 1	Correlación positiva fuerte: cuando una variable sube, la otra tiende a subir.
r cerca de -1	Correlación negativa fuerte: cuando una variable sube, la otra tiende a bajar.
r cerca de 0	No hay relación lineal clara entre las variables.

Ejemplos intuitivos

- Temperatura y venta de helados: si sube la temperatura y suelen venderse más helados, hay correlación positiva.

- Velocidad y tiempo de llegada: si sube la velocidad y baja el tiempo necesario para llegar, hay correlación negativa.
- Número de calzado y nota en un examen: probablemente no haya una relación lineal clara.

Correlación no significa causalidad

Que dos variables estén correlacionadas no significa necesariamente que una cause la otra. Puede haber una tercera variable que explique la relación, o puede ser una coincidencia. Esta idea es fundamental para interpretar datos con cuidado.

Por ejemplo, si aumenta la venta de helados y también aumentan los casos de quemaduras solares, no significa que los helados causen quemaduras. La variable que probablemente influye en ambas cosas es el calor o el buen tiempo.

9. Ejemplo completo paso a paso

Vamos a trabajar con estos datos:

```
datos = [4, 7, 10]
```

Media

```
media = (4 + 7 + 10) / 3 = 7
```

Mediana

```
datos ordenados = [4, 7, 10]  ->  mediana = 7
```

Rango

```
rango = 10 - 4 = 6
```

Varianza

Valor	Valor - media	(Valor - media)^2
4	-3	9
7	0	0
10	3	9

```
varianza = (9 + 0 + 9) / 3 = 6
```

Desviación estándar

```
desviación estándar = raíz cuadrada de 6 ≈ 2.45
```

Interpretación final: el centro de los datos está en 7 y los valores se alejan, de forma aproximada, unos 2.45 puntos respecto a ese centro.

10. Cálculo básico en Python

Python puede ayudarnos a calcular estas medidas. Para empezar, no hace falta entender librerías complejas: basta con saber usar listas, sumas, longitud de una lista y ordenar datos.

```
datos = [4, 7, 10]
media = sum(datos) / len(datos)
datos_ordenados = sorted(datos)
print(media)
print(datos_ordenados)
```

Más adelante, en ciencia de datos, es habitual usar pandas y NumPy. Por ejemplo, una columna de pandas puede calcular media, mediana, varianza y desviación estándar con métodos ya preparados.

```
df["nota"].mean()
df["nota"].median()
df["nota"].var()
df["nota"].std()
```

11. Errores frecuentes al interpretar datos

- Mirar solo la media y olvidar si hay valores extremos.
- Confundir varianza y desviación estándar.
- Pensar que una desviación estándar es una distancia exacta para todos los datos.
- Creer que correlación significa causalidad.
- Comparar variables con escalas muy distintas sin normalizar o estandarizar cuando el análisis lo requiere.
- Olvidar que las fórmulas ayudan, pero la interpretación es lo más importante.

12. Resumen de conceptos

Concepto	Idea principal
Media	Promedio de los valores.
Mediana	Valor central cuando los datos están ordenados.
Moda	Valor que más se repite.
Rango	Diferencia entre máximo y mínimo.
Varianza	Promedio de las diferencias al cuadrado respecto a la media.
Desviación estándar	Raíz cuadrada de la varianza; mide dispersión en las unidades originales.
Normalización	Transforma datos a un rango fijo, como 0 a 1.

Estandarización	Transforma datos según su distancia a la media en desviaciones estándar.
Suma acumulada	Suma progresiva de los valores de una secuencia.
Correlación	Medida de relación lineal entre dos variables.